HuggingFace + Python

# RAG com HuggingFace

Sistema simples de perguntas e respostas usando recuperação de contexto + modelo de IA.

Problema: modelos podem responder sem contexto e gerar informações genéricas ou incorretas.

Solução: recuperar o trecho relevante antes de pedir a resposta ao modelo.



Ref.: huggingface.co | transformers | sentence-transformers

# Como a solução funciona

Fluxo RAG simplificado em Python

1. **Base de conhecimento**
   Pequenos textos sobre IA são armazenados como documentos.

2. **Embeddings**
   Cada texto vira um vetor com sentence-transformers.

3. **Busca semântica**
   A pergunta é comparada com os documentos por similaridade.

4. **Resposta final**
   O contexto recuperado é enviado ao modelo de QA.

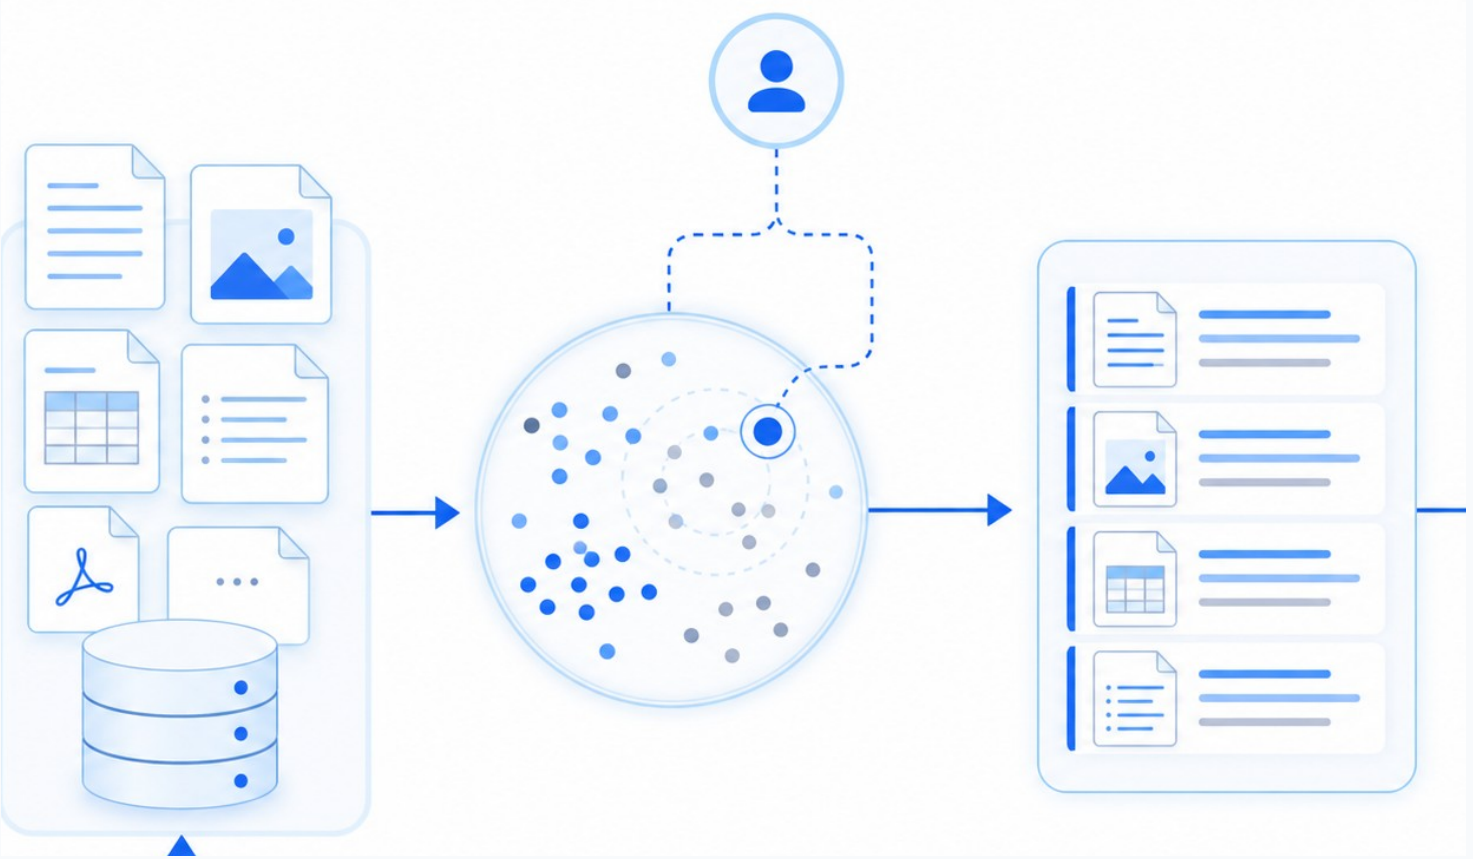

**Bibliotecas usadas: transformers, sentence-transformers, scikit-learn e torch.**



Ref.: huggingface.co | transformers | sentence-transformers

# Resultado obtido

A aplicação recupera o contexto certo e responde com base nele.

## Exemplo de teste

**Pergunta: “O que é RAG?”**

Contexto recuperado: trecho que explica Retrieval Augmented Generation.

Resposta: técnica que combina recuperação de informações com geração de respostas.

## Conclusão
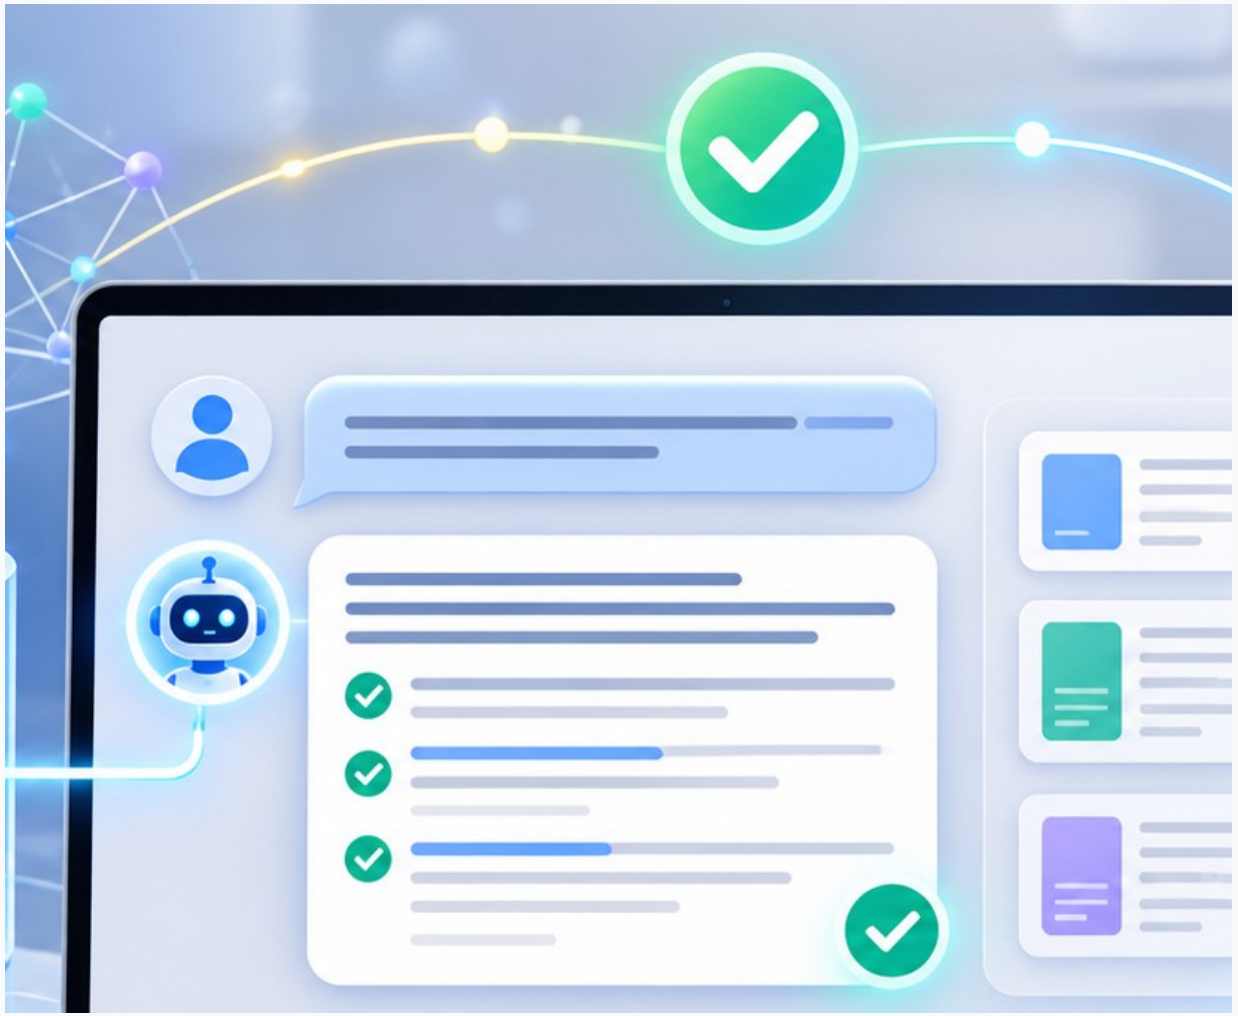
O RAG melhora a qualidade das respostas ao usar informações externas como contexto. O projeto pode ser expandido para PDFs, sites e bases maiores.